



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «ИНЖЕНЕРНЫЙ БИЗНЕС И МЕНЕДЖМЕНТ»

КАФЕДРА «ПРОМЫШЛЕННАЯ ЛОГИСТИКА» (ИБМ-3)

Отчет по лабораторной работе № 1
по дисциплине «Технологии машинного обучения»
«Разведочный анализ данных. Исследование и визуализация данных»

Студент ИБМ 3-64Б

(Подпись, дата)

В.А. Леонтьева

Руководитель

(Подпись, дата)

Ю.Е. Гапанюк

Введение

Целью данной лабораторной работы является изучение методов разведочного анализа данных (Exploratory Data Analysis, EDA), а также получение практических навыков визуализации данных и анализа структуры датасета с использованием Python.

В рамках работы рассматриваются основные способы изучения данных: анализ структуры, построение графиков распределения, исследование взаимосвязей между признаками и анализ корреляции.

Для выполнения лабораторной работы использовались следующие инструменты:

- 1) язык программирования Python;
- 2) библиотека pandas;
- 3) библиотека matplotlib;
- 4) библиотека seaborn;
- 5) библиотека scikit-learn;

1. Описание исходных данных

В качестве исходных данных использован встроенный датасет Iris, который входит в библиотеку scikit-learn.

Данный набор данных содержит информацию о цветках ириса трёх различных видов: Setosa; Versicolor; Virginica;

Каждый объект описывается четырьмя числовыми признаками:

- 1) длина чашелистика (sepal length);
- 2) ширина чашелистика (sepal width);
- 3) длина лепестка (petal length);
- 4) ширина лепестка (petal width).

Всего в датасете содержится 150 наблюдений, по 50 на каждый класс. Целевой признак представляет собой класс цветка.

2. Загрузка и первичный анализ данных

На первом этапе данные были загружены и преобразованы в таблицу DataFrame.

Далее были выполнены следующие операции:

- 1) просмотр первых строк датасета;

- 2) определение размера таблицы;
- 3) анализ типов данных;
- 4) получение статистического описания признаков.

Анализ показал, что датасет не содержит пропущенных значений, все признаки являются числовыми.

3. Визуальный анализ данных

3.1 Гистограммы распределения признаков

Были построены гистограммы для каждого числового признака. Гистограммы позволяют оценить распределение значений и выявить основные диапазоны изменения признаков.




Рис.1 – Гистограммы

Анализ гистограмм показал, что признаки лепестков имеют более выраженную группировку значений и потенциально лучше подходят для разделения классов. Признаки чашелистика распределены более равномерно и обладают меньшей разделяющей способностью. Также установлено, что классы в датасете сбалансированы.

3.2 Диаграммы размаха (Boxplot)

Диаграммы размаха (boxplot) были построены для всех числовых признаков с целью анализа распределения данных и выявления. Что показывает boxplot: медианное значение; интерквартильный диапазон; минимальные и максимальные значения; возможные выбросы.




Рис.2 – Boxplot

Существенных выбросов в данных не обнаружено. Признаки имеют разные масштабы: например, значения длины лепестка значительно меньше или больше в зависимости от класса. Разброс значений у признаков лепестка более выражен, чем у признаков чашелистика.

3.3 Диаграмма рассеивания (Scatter Plot)

Была построена диаграмма рассеяния между длиной чашелистика и длиной лепестка. Точки на графике раскрашены в зависимости от класса цветка. Класс Setosa отделяется от остальных более явно. Классы Versicolor и Virginica частично пересекаются. Между длиной чашелистика и длиной лепестка наблюдается зависимость: при увеличении одного признака увеличивается и другой.




Рис.3 – Scatter Plot

3.4 Корреляционный анализ

Для оценки взаимосвязей между признаками была построена корреляционная матрица. Корреляционный анализ показал сильную положительную связь между длиной и шириной лепестка; слабую корреляцию между остальными признаками; наличие информативных признаков для классификации.




Рис.4 – Корреляционный анализ

Корреляционный анализ показывает, что некоторые признаки избыточно связаны между собой, а другие содержат уникальную информацию, полезную для построения модели.

Заключение

В ходе выполнения лабораторной работы были изучены основные методы разведочного анализа данных.

Были выполнены следующие задачи:

- 1) проведён первичный анализ структуры данных;
- 2) построены графики распределения признаков;
- 3) визуализированы зависимости между признаками;
- 4) выполнен корреляционный анализ.

Полученные результаты позволяют сделать вывод о том, что датасет Iris хорошо структурирован и подходит для задач классификации.

Также были получены практические навыки работы с библиотеками Python для анализа и визуализации данных.

Приложение.

```
import pandas as pd
import matplotlib.pyplot as plt
import seaborn as sns

from sklearn.datasets import load_iris

iris = load_iris()
df = pd.DataFrame(
    iris.data,
    columns=iris.feature_names
)
df["target"] = iris.target

print("Первые 5 строк:")
print(df.head())

print("\nРазмер таблицы:")
print(df.shape)

print("\nИнформация:")
print(df.info())

print("\nСтатистика:")
print(df.describe())

df.hist(figsize=(10,8))
plt.suptitle("Гистограммы")
plt.show()

plt.figure(figsize=(10,6))
sns.boxplot(data=df.iloc[:,0:4])
plt.title("Boxplot")
plt.show()

sns.scatterplot(
    data=df,
    x="sepal length (cm)",
    y="petal length (cm)",
    hue="target"
)
plt.title("Диаграмма рассеяния")
plt.show()

corr = df.corr()

plt.figure(figsize=(8,6))
sns.heatmap(corr, annot=True, cmap="coolwarm")
plt.title("Корреляционная матрица")
plt.show()
```