



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «ИНЖЕНЕРНЫЙ БИЗНЕС И МЕНЕДЖМЕНТ»

КАФЕДРА «ПРОМЫШЛЕННАЯ ЛОГИСТИКА» (ИБМ-3)

Отчет по лабораторной работе № 2
по дисциплине «Технологии машинного обучения»
«Обработка пропусков в данных, кодирование категориальных признаков, масштабирование данных»

Студент ИБМ 3-64Б

(Подпись, дата) В.А. Леонтьева

Руководитель

(Подпись, дата) Ю.Е. Гапанюк

Введение

Целью лабораторной работы является изучение методов предварительной обработки данных, необходимых для последующего построения моделей машинного обучения.

В процессе выполнения работы необходимо освоить основные этапы подготовки данных:

- поиск и обработка пропущенных значений;
- преобразование категориальных признаков в числовой вид;
- масштабирование числовых признаков.

Предварительная обработка данных является важнейшим этапом анализа данных, так как качество обучаемой модели напрямую зависит от качества входных данных.

Для выполнения лабораторной работы необходимо выбрать набор данных, содержащий категориальные признаки и числовые параметры.

Для выбранного датасета требуется выполнить следующие действия:

- 1) загрузить данные из файла CSV;
- 2) выполнить анализ структуры данных;
- 3) проверить наличие пропусков;
- 4) выполнить обработку пропущенных значений;
- 5) выполнить кодирование категориальных признаков;
- 6) выполнить масштабирование числовых признаков.

1. Описание используемого набора данных

В работе использован набор данных, содержащий сведения о специалистах различных профессий и уровне их заработной платы.

Каждая строка таблицы соответствует отдельному сотруднику.

Датасет содержит следующие признаки:

Признак	Описание
job_title	должность сотрудника
experience_years	количество лет опыта
education_level	уровень образования
skills_count	количество профессиональных навыков
industry	отрасль компании
company_size	размер компании
location	страна
remote_work	формат работы
certifications	количество сертификатов
salary	заработная плата

Данный набор данных подходит для задач прогнозирования уровня заработной платы и анализа факторов, влияющих на доход сотрудников.

2. Ход выполнения работы

2.1 Загрузка данных и первичный анализ

На первом этапе данные были загружены из CSV-файла в структуру DataFrame библиотеки pandas:

```
df = pd.read_csv("job_salary_prediction_dataset.csv")
```

После загрузки была выполнена проверка содержимого таблицы, просмотрены первые строки и структура признаков.

```
print("Первые 5 строк:")  
print(df.head())
```

Это необходимо для понимания формата данных и выбора методов дальнейшей обработки.

```
Первые 5 строк:  
   job_title  experience_years  education_level  ...  remote_work  certifications  salary  
0  AI Engineer              10      Bachelor  ...      Hybrid           2    109413  
1  Data Analyst              5      Bachelor  ...           No           0     93764  
2  Frontend Developer        18           PhD  ...           No           1    148123  
3  Business Analyst         19           PhD  ...          Yes           0    189123  
4  Product Manager         15      Bachelor  ...          Yes           0    165069  
  
[5 rows x 10 columns]  
  
Размер таблицы:  
(250000, 10)
```

Рис.1 – Вывод первых 5 строк

2.2 Проверка пропусков в данных

Пропущенные значения представляют собой пустые ячейки таблицы. Большинство алгоритмов машинного обучения не умеют работать с такими значениями напрямую, поэтому пропуски необходимо предварительно обработать.

```
print(df.isnull().sum())
```

После выполнения программы был получен следующий результат:

```
После заполнения пропусков:  
job_title      0  
experience_years  0  
education_level  0  
skills_count    0  
industry        0  
company_size    0  
location        0  
remote_work     0  
certifications  0  
salary          0  
dtype: int64
```

Рис.2 – Заполнение пропусков

Это означает, что после обработки во всех столбцах отсутствуют пропущенные значения.

2.3 Обработка пропусков

Для обработки пропусков использовались следующие подходы:

1) для числовых признаков: пропущенные значения заменялись средним значением столбца. Например: `skills_count` = среднее значение по столбцу. Такой метод позволяет сохранить структуру данных и не удалять строки.

```
df["skills_count"].fillna(df["skills_count"].mean(), inplace=True)
```

2) для категориальных признаков: пропущенные значения заменялись наиболее часто встречающимся значением. Например: `education_level` = наиболее частое значение. Это распространённый метод обработки категориальных данных.

```
df["education_level"].fillna(df["education_level"].mode()[0], inplace=True)
```

После добавления пропусков:		После заполнения пропусков:	
job_title	0	job_title	0
experience_years	0	experience_years	0
education_level	1	education_level	0
skills_count	1	skills_count	0
industry	0	industry	0
company_size	0	company_size	0
location	0	location	0
remote_work	0	remote_work	0
certifications	0	certifications	0
salary	0	salary	0

Рис.3 – Результат добавления и устранения пропусков

Использованный подход позволяет минимизировать потери информации.

2.4 Кодирование категориальных признаков

Большинство алгоритмов машинного обучения работают только с числовыми значениями. Поэтому текстовые признаки необходимо преобразовать в числа. Для этого использовался метод Label Encoding.

Пример результата после кодирования:

```
job_title:
  AI Engineer -> 0
  Data Analyst -> 5
  Frontend Developer -> 8
  Business Analyst -> 2
  Product Manager -> 10
```

Фрагмент таблицы после кодирования:

После кодирования:							
	job_title	experience_years	education_level	...	remote_work	certifications	salary
0	0	10	3	...	0	2	109413
1	5	5	0	...	1	0	93764
2	8	18	4	...	1	1	148123
3	2	19	4	...	2	0	189123
4	10	15	0	...	2	0	165069

Рис.4 – Результат кодирования таблицы

Каждому уникальному текстовому значению присваивается числовой код. Это позволяет использовать данные в алгоритмах машинного обучения. Все категориальные признаки были успешно преобразованы в числовой формат.

2.5 Масштабирование данных

Числовые признаки могут иметь разные диапазоны значений. Например: experience_years = от 0 до 20; salary = от 90000 до 200000.

Если признаки имеют разный масштаб, некоторые алгоритмы начинают считать большие числа более важными. Для устранения этой проблемы было применено масштабирование методом StandardScaler. После масштабирования признаки приводятся к следующему виду: среднее значение около 0; стандартное отклонение около 1.

Фрагмент результата:

После масштабирования:							
	job_title	experience_years	education_level	...	remote_work	certifications	salary
0	0	-0.000892	3	...	0	-0.288272	-0.970520
1	5	-0.825894	0	...	1	-1.460281	-1.388854
2	8	1.319111	4	...	1	-0.874276	0.064289
3	2	1.484112	4	...	2	-1.460281	1.160315
4	10	0.824110	0	...	2	-1.460281	0.517295

Рис.5 – Результат масштабирования таблицы

Теперь все числовые признаки находятся в сопоставимом масштабе. Масштабирование повышает качество работы многих алгоритмов машинного обучения.

Заключение

В результате выполнения лабораторной работы были успешно выполнены все поставленные задачи:

- 1) данные загружены и исследованы;
- 2) пропуски обработаны;
- 3) категориальные признаки преобразованы в числовой формат;

4) числовые признаки масштабированы.

Подготовленный датасет может использоваться для построения моделей машинного обучения.

Предварительная обработка данных является обязательным этапом перед обучением моделей, так как позволяет повысить точность и устойчивость алгоритмов.

Приложение. Текст программы

```
import pandas as pd
from sklearn.preprocessing import LabelEncoder, StandardScaler

df = pd.read_csv("job_salary_prediction_dataset.csv")

print("Первые 5 строк:")
print(df.head())

print("\nРазмер таблицы:")
print(df.shape)

print("\nПропуски по столбцам:")
print(df.isnull().sum())

# создадим пропуски
df.loc[0, "education_level"] = None
df.loc[3, "skills_count"] = None

print("\nПосле добавления пропусков:")
print(df.isnull().sum())

df["skills_count"].fillna(df["skills_count"].mean(), inplace=True)

df["education_level"].fillna(df["education_level"].mode()[0], inplace=True)

print("\nПосле заполнения пропусков:")
print(df.isnull().sum())

cat_cols = [
    "job_title",
    "education_level",
    "industry",
    "company_size",
    "location",
    "remote_work"
]

encoder = LabelEncoder()

for col in cat_cols:
    df[col] = encoder.fit_transform(df[col])

print("\nПосле кодирования:")
print(df.head())

num_cols = [
    "experience_years",
    "skills_count",
    "certifications",
    "salary"
]

scaler = StandardScaler()

df[num_cols] = scaler.fit_transform(df[num_cols])

print("\nПосле масштабирования:")
print(df.head())
```